Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа №2-3 по дисциплине «Методы машинного обучения»

на тему

«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных. Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей»

Выполнил: студент группы ИУ5-14М Подопригорова Н. С.

1. Лабораторная №2

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Задание:

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - устранение пропусков в данных;
 - кодирование категориальных признаков;
 - нормализация числовых признаков.

2. Melbourne Housing Snapshot

- Rooms: Number of rooms
- Price: Price in dollars
- Method: S property sold; SP property sold prior; PI property passed in; PN sold prior not disclosed; SN - - sold not disclosed; NB - no bid; VB - vendor bid; W - withdrawn prior to auction; SA - sold after auction; SS - sold after auction price not disclosed. N/A - price or highest bid not available.
- Type: br bedroom(s); h house,cottage,villa, semi,terrace; u unit, duplex; t townhouse; dev site - development site; o res other residential.
- SellerG: Real Estate Agent
- Date: Date sold
- Distance: Distance from CBD
- Regionname: General Region (West, North West, North, North east ...etc)
- Propertycount: Number of properties that exist in the suburb.
- Bedroom2 : Scraped # of Bedrooms (from different source)
- Bathroom: Number of Bathrooms
- Car: Number of carspots
- · Landsize: Land Size
- BuildingArea: Building Size
- CouncilArea: Governing council for the area

```
[14]: import sklearn
from sklearn.model_selection import train_test_split
from sklearn.impute import SimpleImputer
import pandas as pd
import numpy as np
import seaborn as sns
import scipy.stats as stats
import matplotlib.pyplot as plt
```

```
[3]: data = pd.read_csv('melb_data.csv')
```

```
[25]: data.head()
[25]:
             Suburb
                               Address
                                        Rooms Type
                                                         Price Method SellerG
      0
         Abbotsford
                         85 Turner St
                                            2
                                                 h
                                                     1480000.0
                                                                    S
                                                                       Biggin
      1
        Abbotsford
                      25 Bloomburg St
                                            2
                                                     1035000.0
                                                                    S
                                                                       Biggin
                                                 h
      2 Abbotsford
                          5 Charles St
                                            3
                                                 h
                                                     1465000.0
                                                                   SP
                                                                       Biggin
      3 Abbotsford
                    40 Federation La
                                            3
                                                                   PΙ
                                                                       Biggin
                                                 h
                                                      850000.0
      4 Abbotsford
                           55a Park St
                                            4
                                                     1600000.0
                                                                       Nelson
                                                 h
                                                                   VΒ
              Date Distance
                              Postcode
                                            Bathroom
                                                       Car
                                                            Landsize
                                                                      BuildingArea
      0
        3/12/2016
                         2.5
                                 3067.0
                                                       1.0
                                                               202.0
                                                  1.0
                                                                                NaN
        4/02/2016
      1
                         2.5
                                 3067.0
                                                  1.0
                                                       0.0
                                                               156.0
                                                                               79.0
      2 4/03/2017
                         2.5
                                                  2.0
                                                       0.0
                                                               134.0
                                                                              150.0
                                 3067.0
      3 4/03/2017
                         2.5
                                 3067.0
                                                  2.0
                                                       1.0
                                                                94.0
                                                                                NaN
      4 4/06/2016
                         2.5
                                 3067.0
                                                  1.0 2.0
                                                               120.0
                                                                              142.0
         YearBuilt
                    CouncilArea Lattitude
                                            Longtitude
                                                                    Regionname
                          Yarra
      0
                                 -37.7996
                                               144.9984
                                                         Northern Metropolitan
               NaN
      1
            1900.0
                          Yarra -37.8079
                                               144.9934 Northern Metropolitan
      2
            1900.0
                                 -37.8093
                                                         Northern Metropolitan
                          Yarra
                                               144.9944
      3
                                  -37.7969
                                                         Northern Metropolitan
                          Yarra
                                               144.9969
               {\tt NaN}
      4
            2014.0
                           Yarra
                                  -37.8072
                                               144.9941
                                                         Northern Metropolitan
        Propertycount
      0
               4019.0
      1
               4019.0
      2
               4019.0
      3
               4019.0
      4
               4019.0
```

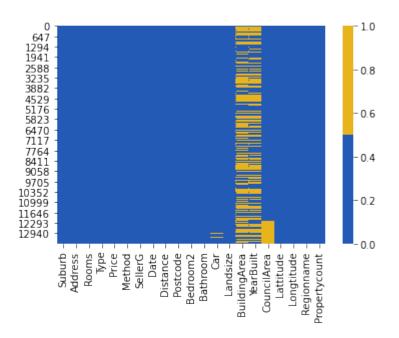
2.1. Обработка пропусков в данных

[5 rows x 21 columns]

Желтый - пропущенные данные, синий - не пропущенные

```
[10]: cols = data.columns
  colours = ['#235AB5', '#E8B41E']
  sns.heatmap(data[cols].isnull(), cmap=sns.color_palette(colours))
```

[10]: <matplotlib.axes._subplots.AxesSubplot at 0x7fad56bcb940>



[9]: data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 13580 entries, 0 to 13579
Data columns (total 21 columns):


#	Column	Non-Null Count	Dtype
0	Suburb	13580 non-null	object
1	Address	13580 non-null	object
2	Rooms	13580 non-null	int64
3	Туре	13580 non-null	object
4	Price	13580 non-null	float64
5	Method	13580 non-null	object
6	SellerG	13580 non-null	object
7	Date	13580 non-null	object
8	Distance	13580 non-null	float64
9	Postcode	13580 non-null	float64
10	Bedroom2	13580 non-null	float64
11	Bathroom	13580 non-null	float64
12	Car	13518 non-null	float64
13	Landsize	13580 non-null	float64
14	BuildingArea	7130 non-null	float64
15	YearBuilt	8205 non-null	float64
16	CouncilArea	12211 non-null	object
17	Lattitude	13580 non-null	float64
18	Longtitude	13580 non-null	float64
19	Regionname	13580 non-null	object
20	Propertycount	13580 non-null	float64
dtypes: float64(12), int64(1), object(8)			


memory usage: 2.2+ MB


Рассмотрим числовые колонки с пропущенными значениями

```
Car. float64. 62, 0.46%.
BuildingArea. float64. 6450,
47.5%.
YearBuilt. float64. 5375, 39.58%.
```

```
[5]: data_num = data[num_cols]
  for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```







Выбросов нет, распределения одномодальные

```
[6]: data = data.fillna(data.mode())
```

Рассмотрим пропуски в категориальных данных

CouncilArea.

object.

1369, 10.08%.

```
[8]: data[:] = SimpleImputer(missing values=np.nan, strategy='most frequent').
       →fit_transform(data)
[17]: data.isnull().sum()
[17]: Suburb
                       0
     Address
                       0
     Rooms
                       0
                       0
     Type
     Price
                       0
     Method
                       0
     SellerG
                       0
     Date
                       0
                       0
     Distance
     Postcode
                       0
     Bedroom2
                       0
     Bathroom
                       0
     Car
                       0
     Landsize
                       0
     BuildingArea
                       0
     YearBuilt
                       0
     CouncilArea
                       0
                       0
     Lattitude
     Longtitude
                       0
     Regionname
                       0
     Propertycount
                       0
     dtype: int64
```

Все пропуски в данных заполнены

2.2. Кодирование категориальных признаков

Рассмотрим количество категорий в признаках типа object

: 314 Suburb. Address. : 13378 : 3 Type. Method. : 5 SellerG. : 268 : 58 Date. CouncilArea. : 33 : 8 Regionname.

В признаках Suburb, Address, SellerG, CouncilArea слишком много категорий для OneHotEncoder, так что используем LabelEncoder.

```
[18]: from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
categorical1 = ['Suburb', 'Address', 'SellerG', 'CouncilArea']
for col in categorical1:
    data[col] = le.fit_transform(data[col])
```

Для остальных признаков используем OneHotEncoder

Дату обработаем отдельно

```
[20]: import datetime as dt

data['Date'] = pd.to_datetime(data['Date'])
data['Date'] = data['Date'].map(dt.datetime.toordinal)
```

```
[35]: data.shape
```

[35]: (13580, 31)


2.3. Нормализация числовых признаков

```
[52]: total_count = data.shape[0]
num_cols = []
for col in data.columns:
    dt = str(data[col].dtype)
    if dt=='float64' or dt=='int64':
        num_cols.append(col)
```


```
[53]: data[num_cols] = data[data[num_cols] > 0][num_cols]
```


```
[50]: def diagnostic_plots_data(df):
    plt.figure(figsize=(15,6))
    plt.subplot(1, 2, 1)
    df.hist(bins=30)
    plt.subplot(1, 2, 2)
    stats.probplot(df, dist="norm", plot=plt)
    plt.show()
```


```
[54]: data[num_cols].hist(figsize=(20,20))
plt.show()
```




```
[59]: diagnostic_plots_data(data['Price']) diagnostic_plots_data( np.log(data['Price']) )
```













```
[65]: diagnostic_plots_data(data['Distance'])
    diagnostic_plots_data( data['Distance']**(1/3) )
```













```
[57]: diagnostic_plots_data(data['Rooms']) diagnostic_plots_data( data['Rooms']**(1/10) )
```










```
[23]: diagnostic_plots_data(data['YearBuilt'])

data['YearBuilt_boxcox'], param = stats.boxcox(data['YearBuilt'])
print(' = {}'.format(param))
diagnostic_plots_data(data['YearBuilt_boxcox'])
```



= 18.95465909623817

